

parser3 — руководство пользователя

Парсер контактов лиц, принимающих решения (ЛПР), с корпоративных сайтов. Ты даёшь ему список сайтов — он обходит их, вытаскивает ФИО, должности, телефоны, email, соцсети и реквизиты компаний, раскладывает по ролям и отдаёт готовый Excel-файл.

Извлечение полностью классическое: обход страниц, разбор HTML, словарь должностей, морфология и нечёткое сопоставление. **Никакого ИИ/нейросетей внутри нет** — всё детерминировано.

Где открыть. Приложение живёт по субпути на сервере: рабочая (dev) версия — `/parser3-dev/`, стабильная (prod) — `/parser3/`. Обе — один и тот же интерфейс. Доступ закрыт паролем (Basic Auth), логин/пароль спросит браузер.

С чего начать

На главной странице — форма **«Новая задача»**. Скормить сайты можно двумя способами; оба создают одну задачу.

Способ 1 — вставить список. В большое текстовое поле — по одному сайту/домену на строку. Правила:

- строка без `http://` / `https://` автоматически дополняется до `https://`;
- пустые строки игнорируются;
- строки, начинающиеся с `#`, считаются комментариями и пропускаются.

Способ 2 — загрузить файл `.csv` или `.txt` (кнопка «Загрузить CSV/TXT»). Разбор построчный:

- из CSV берётся первый «похожий на ссылку» кусок строки (тот, где есть точка);
- строки-заголовки (`url`, `сайт`, `site`, `website`, `домен`) пропускаются;
- строки с `#` пропускаются.

Дубликаты схлопываются. Одинаковые URL внутри одной задачи объединяются. Поэтому «строк в файле» почти всегда больше, чем «уникальных сайтов» в задаче — это нормально, а не потерянные данные.

Ограничения на размер файла — до 50 МБ. Жёсткого потолка на количество сайтов в задаче нет.

Режимы парсинга

В форме есть селект **«Режим»** с двумя вариантами.

Все контакты ((all_contacts))

Тянет все найденные контакты со всех обойденных страниц сайта. Глубина обхода — до 15 страниц на сайт. Бери, когда нужна полная выгрузка по компании.

По списку должностей ((target_positions))

Появляются 4 чекбокса групп должностей:

- Генеральные директора;
- Финансовые директора;
- Главные бухгалтеры;
- Главные инженеры.

Контакт остаётся в результате, только если его должность (как на сайте или после нормализации) содержит одно из ключевых слов выбранных групп ((генеральный директор), (финансовый директор), (главный бухгалтер), (главный инженер), (президент) и т.п.). Компания-«заглушка» без ФИО всё равно добавляется — чтобы сайт не потерялся из отчёта.

Есть ещё внутренний ускоренный режим ((fast_start)) (обход 6 страниц вместо 15), но в интерфейс он не выведен.

Что на выходе

На каждую задачу формируется **один XLSX-файл** ((parser3_<номер задачи>.xlsx)). Плюс контакты можно смотреть прямо в интерфейсе и выгрузить в CSV.

Формат	Что содержит	Как получить
XLSX	всё: 8 листов с ролями, сводкой и качеством	кнопка «Скачать XLSX»
CSV	только лист «Все контакты», разделитель (;), UTF-8	кнопка «Скачать CSV»
Просмотр в UI	первые 500 контактов задачи	страница задачи

Экспорта в JSON нет (JSON отдаёт только API «вживую»).

Листы XLSX

Файл состоит из 8 листов:

1. Генеральные директора
2. Финансовые директора
3. Главные бухгалтеры
4. Главные инженеры

5. **Остальные** — всё, что не попало в ролевые листы
6. **Все контакты** — плоский полный список
7. **Сводка** — параметры задачи и счётчики по каждому листу
8. **Отчёт качества** — метрики полноты: сколько контактов с ФИО, с должностью, с телефоном, с email, с ИНН; сколько `(partial)` / `(error)`; разбивка по методу нормализации

Как контакт попадает в ролевой лист. Только если распознано непустое ФИО и нормализатор отнёс должность к этой роли. Иначе — в «Остальные». Заместители и «исполнительные директора» в ролевые листы **не** попадают (они в списке исключений) — это by design, а не баг.

Колонки контакта (29 штук)

Порядок в XLSX точный:

№ · Компания · Сайт · ИНН · КПП · ОГРН · Наимен. по реквизитам ·
Общий email · Общий телефон · ФИО (полностью) · Фамилия · Имя · Отчество ·
Имя Отчество · Пол · Фамилия И.О. (дат.) · Окончание · Должность (как на сайте) ·
Должность (норм.) · Категория отрасли · Метод нормализации · Личный email ·
Личный телефон · Соцсети · URL источника · Язык · Дата · Статус · Комментарий

Отдельно стоит понимать пары «сырое / нормализованное»:

- **Должность (как на сайте)** — как написано на странице; **Должность (норм.)** — приведённая к каталогу.
- **Фамилия И.О. (дат.)** — фамилия с инициалами в дательном падеже (для писем «кому: Иванову И.И.»); **Окончание** — подобранное окончание.
- **Пол** определяется по ФИО автоматически.

Как читать результат и следить за задачей

Страница задачи

Открывается по клику на задачу в таблице. На ней:

- **статус-бейдж** и **прогресс-бар** — считается по *уникальным* сайтам (после схлопывания дубликатов), плюс «Сейчас: <адрес>» и оценка оставшегося времени (ETA);
- кнопки **Пауза** / **Продолжить** / **Отменить**;
- кнопки скачивания: **XLSX**, **CSV**, **исходный файл**;
- таблица **«Сайты»** — по каждому статус и, если была ошибка, её причина;

- таблица «**Контакты**» — первые 500 (полный список — только в XLSX).

Обновления идут «вживую» (через WebSocket) плюс подстраховка опросом раз в 3 секунды. Список задач на главной обновляется раз в 5 секунд.

Статусы задачи

`pending` (в очереди) → `running` (обрабатывается) → `completed` (готово). Промежуточно возможны `paused` (на паузе), `cancelled` (отменена), `failed` (упала целиком).

Статусы и цвета по сайтам

Статус	Значит
<code>ok</code>	сайт обработан, контакты найдены
<code>partial</code>	данные компании есть, но персональных ФИО не нашли — строка жёлтая
<code>error</code>	сайт не удалось обработать — строка красная
<code>pending</code> / <code>processing</code>	ещё в очереди / в работе

Почему сайт не спарсился (коды ошибок человеческим языком)

Код	Что произошло
<code>dns_nxdomain</code>	домен не существует
<code>dns_timeout</code>	DNS не ответил вовремя
<code>ssl_error</code>	проблема с HTTPS-сертификатом
<code>conn_refused</code> / <code>conn_error</code>	сервер отклонил соединение / сетевая ошибка
<code>connect_timeout</code> / <code>read_timeout</code> / <code>timeout</code>	сайт слишком медленный
<code>http_403</code>	доступ запрещён (403)
<code>http_429</code>	сработала защита от частых запросов (429)
<code>http_4xx</code> / <code>http_5xx</code>	прочие ошибки клиента / сервера
<code>empty_html</code>	страница пустая, парсить нечего

Код	Что произошло
<code>fetch_failed</code> / <code>exception</code>	не удалось загрузить / внутренняя ошибка

При таймауте строка сайта оранжевая, при NXDOMAIN — жёлтая, остальное красным.

Чёрный список

В приложении есть чёрный список — исключения, которые выкидываются из результатов. Добавить/убрать можно четыре типа записей:

- **должность** — не тянуть контакты с такой должностью;
- **ФИО** — исключить конкретного человека;
- **email** — исключить адрес;
- **домен** — целиком игнорировать сайт.

Полезно, когда в выгрузку раз за разом лезет мусор (тех-поддержка, общие почтовые ящики, «дежурные» ФИО).

Что важно помнить

- **ИИ внутри нет.** Качество зависит от того, насколько аккуратно контакты размечены на самом сайте (таблицы «должность — ФИО», карточки руководства).
- **В UI видно только 500 контактов** — за полным списком всегда в XLSX.
- **Дубли сайтов схлопываются** внутри задачи — не пугайся расхождения чисел.
- **Замы и и.о. не идут в ролевые листы** — ищи их в «Остальных».
- **Пароля/лимита запросов в самом приложении нет** — доступ закрывает пароль на уровне сервера (браузер спросит при входе).